

SEW-Offload: 面向昇腾 NPU 的 MoE Expert Offloading

Static Expert-Slot Windowing for Ascend MoE Offloading

不要把 NPU 当 GPU 用： 重点研究如何利用 Ascend 的差异化特性重塑 MoE expert offloading 的设计空间，并据此重新设计专家权重驻留、搬运、窗口化执行与预取机制。

What is your problem

问题背景

混合专家模型通过为每个 token 仅激活少量专家来扩展模型容量，但专家权重本身仍然给推理阶段的设备显存带来巨大压力。专家卸载因此成为在有限 HBM 条件下部署大规模 MoE 模型的重要路径。然而，现有 MoE offloading 系统大多沿用 GPU 时代的抽象，主要关注哪些专家应常驻显存、缺失专家何时从主机侧加载，以及如何进行专家缓存和预取。

现有方法的 GPU 假设

- **expert caching**: 把 HBM 看作 expert cache，热 expert 常驻，冷 expert 放在 host；
- **host-to-device prefetching**: 根据历史路由或预测提前把可能需要的 expert 搬到设备；
- **CUDA stream overlap**: 依赖动态 kernel、stream 并发和异步拷贝隐藏传输开销。

为什么在 Ascend 上不完整

- **稳定 tensor 地址**: expert 动态装载会改变权重入口，削弱地址绑定和 buffer 复用；
- **固定 shape 与图重放**: active expert 和 token count 每轮变化，放大 graph/static-kernel 变体；
- **显式调度的数据移动**: H2D/MTE 搬运若不能被明确编排，会暴露为计算等待；

核心问题定义: 现有的 MoE 卸载系统通常将专家权重视为动态缓存的设备对象，并通过缓存替换、主机到设备的预取以及流级拷贝与计算重叠来降低传输开销。但这种设计思路对昇腾 NPU 而言并不充分。在 HBM 容量受限的情况下，将专家动态加载到任意的设备缓冲区中，会与昇腾执行所依赖的**稳定权重地址、固定执行窗口、图重放和显式数据移动调度**产生冲突。因此，卸载后的 MoE 推理要么让主机到 HBM 的专家加载暴露在关键路径上，要么就不得不放弃高效 NPU 执行所需的静态执行规整性。

Why it matters?

MoE、Ascend 与 offloading 三个层面的必要性

随着 DeepSeek-V3/R1、Qwen-MoE、Mixtral 等模型普及，MoE 已成为大模型扩展的重要方向。问题不再只是能不能训练更大的模型，而是如何让超大 expert 参数在真实硬件上高效服务。

1. 为什么 MoE 很重要

- **扩展参数规模：**拥有巨大专家参数池，但每个 token 只激活少量 expert；
- **提高推理性价比：**相比同等总参数 dense 模型，用稀疏激活降低单 token 计算量；
- **代表前沿趋势：**DeepSeek、Qwen、Mixtral 表明，大规模 MoE 已成为高能力模型的重要形态。

2. 为什么 Ascend 上重要

- **国产算力主战场：**生产环境依赖 Ascend 910B/910C，MoE 能否跑好直接影响算力可用性；
- **不能只复制 GPU：**Ascend 更强调稳定地址、固定 shape、图重放和显式搬运调度；
- **需要 NPU-native 路线：**把 MoE 适配 Ascend，才能释放 AIC/AIV/MTE 等硬件能力。

3. 为什么 Ascend offload 重要

- **HBM 直接卡部署：**大 MoE expert 权重放不下单卡 HBM，必须有可用卸载路径；
- **GPU-style offload 不够：**expert cache/prefetch 会破坏稳定地址、固定窗口和图重放；
- **必须保住 NPU 效率：**既要省 HBM，又要让权重加载、MTE 和 grouped MLP 规整调度。

核心动机：MoE 决定了前沿模型的扩展方向，Ascend 决定了这些模型在国产算力上的落地能力；而 Ascend expert offloading 决定了在 HBM 受限时，能否把“参数很大但激活稀疏”的 MoE 真正高效部署起来。SEW-Offload 的价值正是在 Ascend 约束下，把动态 expert 工作集转化为可复用、可预取、可流水化的固定 slot 执行窗口。

Why existing work fails?


现有工作各自解决了局部问题，但没有同时覆盖 “Ascend + HBM 受限 + expert offload”。

工作类型	代表工作	做法	现有不足
GPU MoE offload	MoE-Infinity; Fiddler	将 expert 作为 GPU cache/CPU-GPU 协同对象，利用 activation trace、专家热度或执行策略决定缓存替换、预取和 CPU/GPU 分工。	优化目标主要是减少 CPU-GPU 传输和提高 GPU 资源利用；默认动态 expert 对象、动态入口和 stream overlap 可接受，未处理 Ascend 对稳定权重地址、固定窗口、图重放和 MTE 编排的要求。
Ascend 全量 MoE	vLLM Ascend AscendFusedMoE; npugrouped_matmul	将 routing 结果整理成 per-expert count/group_list，再调用 Ascend grouped matmul 执行 MoE MLP。	默认 expert 权重已经全量驻留 HBM；没有 host expert store、固定 resident slot、miss/prefetch/replacement，也没有针对 offload miss 的分阶段执行。
非 Ascend NPU MoE	NPUMoE	面向 Apple ANE，将 dense/static compute offload 到 NPU；动态 routing、top-k、scatter/gather 等不规则部分走 CPU/GPU fallback，并用 static tiers/grouped execution/graph residency 降低开销。	目标硬件、内存体系和 runtime 不同；解决的是 ANE 静态图与动态算子回退问题，不解决 Ascend 上 host-to-HBM expert 权重装载、稳定 slot 入口和 MTE/Cube 流水。

研究空白： 缺少面向 Ascend 的 **HBM 受限 expert offloading**：不改变 router/top-k/token 语义，同时处理权重驻留、搬运隐藏和稳定执行入口。

What is your key idea?

把 expert offloading 从 “cache hit rate 问题” 改写为 “可静态化、可预取、可分阶段执行的调度问题”。



核心思路：先给 NPU 预留一组固定的专家位置，让执行入口和权重地址保持稳定；再根据每个缺失专家什么时候会被用到、搬运代价有多高、影响多少 token，决定先搬谁；如果仍然来不及搬完，就先执行已经在显存里的专家，同时继续搬运缺失专家，避免整层 MoE 因少数缺失专家而停住。

Old assumption fails: 旧 GPU 假设为什么不够

旧假设：expert cache 是主要问题

GPU MoE offloading 常把系统抽象成：

- router 产生动态 expert 集合；
- runtime 根据热度/预测决定加载哪些 expert；
- expert kernel 对当前 batch 动态执行；
- cache 命中率和传输带宽决定性能。

在 Ascend 上缺失的约束

如果只复制 GPU cache 策略，会忽略：

- graph capture 依赖稳定 tensor 形状和地址；
- static kernel 编译启动成本高，但重复执行收益大；
- MTE 搬运和 Cube 计算需要被流水化；
- 小而动态的 expert 执行会放大队列和调度开销。

重新定义 offloading： 在 Ascend 上，offloading 不只是“expert 在 host 和 device 之间移动”，还包括**权重驻留位置、slot 地址稳定性、图复用粒度、预取流水**这些 GPU 工作通常弱化的控制面。

Important correction: vLLM Ascend 已经做了什么

我们不能把已有 grouped MoE 后端当成新贡献。

路径	已有机制	含义
MC2	<code>npu_moe_distribute_dispatch</code> 返回 <code>expert_token_nums</code>	dispatch 后已有每个 expert 的累计 token 边界
AllGather	<code>npu_moe_init_routing</code> 返回 <code>expert_tokens</code>	token-level routing 被整理为 per-expert count
All2AllV	<code>torch.histc(topk_ids)</code> 统计 <code>tokens_per_expert</code>	expert 粒度统计用于通信和 GMM
MLP	<code>npu_grouped_matmul(... group_list=...)</code>	后端按 expert 分组执行矩阵乘

修正后的边界： vLLM Ascend 已经解决了“per-token assignment 到 per-expert count/grouped execution” 的表示问题。SEW-Offload 不能声称这是贡献；我们的目标是在此基础上解决HBM 不足时 expert 权重不再全量常驻的问题。

What is still missing: grouped count 不是 offloading window

已有 grouped MoE 后端

- 输入仍是每轮动态 topk_ids;
- group_list 的形状固定, 但 count 数值动态;
- GMM 根据每轮 split_value 决定 expert 的 M 维;
- 权重张量来自 layer.w13_weight/w2_weight。

Offloading 需要的新抽象

- HBM 中只有固定数量 expert_slots;
- expert_id -> slot_id 动态映射;
- slot 内权重 tensor 地址长期稳定;
- miss expert 触发加载、替换或慢速 fallback;
- slot 作为 graph/static-kernel 的稳定输入。

关键差异: grouped count 解决的是 activation 如何按 expert 执行; SEW-Offload 解决的是 expert 权重如何在 HBM 受限时以固定 slot 方式驻留、加载和复用。

Opportunity: Ascend 给 MoE offloading 的新控制面

Graph / static kernel

ACLGraph/NPUGraph 和 static kernel 更偏好固定 shape、固定 tensor 地址与有限执行变体。这意味着 expert offloading 应该尽量让 device 侧权重入口稳定。

Weight prefetch

vLLM Ascend 已经有通过额外 pipeline 预取线性层权重、降低 MTE 压力的经验。Expert slot 可以把“预取哪些权重”变成显式策略问题。


AIC/AIV/MTE 分工

MoE 执行天然包含 routing、permute、grouped GEMM、combine 与权重搬运。Ascend 的矩阵单元、向量单元和搬运单元让这些阶段有机会流水化。

Fixed GM window

如果 NPU 侧只有固定数量 slot，且每个 slot 的权重布局固定，runtime 可以把动态 expert 工作集翻译为稳定的 slot 执行窗口。

Key idea: Static Expert-Slot Windowing



核心理想： 不改变 router 选出的 expert；只是在执行前，把 active expert 映射到固定数量、固定地址的 HBM slots。命中的 expert 直接执行，未命中的 expert 触发加载/替换/降级路径。

Runtime abstraction

抽象	职责	为什么是 Ascend-specific
ExpertStore	CPU/host 侧保存完整 expert 权重, 支持按 expert 或 tile 加载	把 offloading 从一次性全量权重迁移变成可调度的数据搬运
SlotManager	维护固定数量 HBM slots 与 expert_id -> slot_id	固定 slot tensor 地址, 给 graph/static kernel 稳定入口
WindowPlanner	根据 group_list、历史热度和 HBM budget 选择 resident set	利用已有 per-expert count, 而不是重新做 routing
PrefetchEngine	在 routing/dispatch/GMM 间隙预取下一层或下一步 expert	显式利用 MTE/权重预取流水, 降低 Cube 等待
FallbackPath	处理 slot miss、超预算、预取失败和未覆盖 expert	保证不 drop token, 不改变模型语义

One iteration data flow

- ① **Routing:** 原始 router 产生 `topk_ids/topk_weights`, 不修改激活结果。
- ② **Count extraction:** 复用现有 `token_dispatcher.py` 得到 `group_list/expert_tokens`。
- ③ **Working-set planning:** 根据当前层 active experts、历史局部性和 slot budget 决定 resident set。
- ④ **Slot remap:** 将 active expert 映射到 `slot_id`, 构造 slot-local expert map。
- ⑤ **Load/prefetch:** 对 miss expert 从 host store 加载到空闲或被替换 slot。
- ⑥ **Grouped MLP:** 使用 slot 权重和现有 grouped matmul 路径执行。
- ⑦ **Combine:** 复用现有 `combine/unpermute`, 还原原始 token 顺序。

语义保证: SEW-Offload 只改变 expert 权重的驻留和访问方式, 不改变 router logits、top-k expert、gate weight 或 combine 语义。

Integration in vLLM Ascend

现有主路径

- 1 AscendFusedMoE.forward_impl
- 2 select_experts
- 3 build_fused_experts_input
- 4 moe_comm_method.fused_experts
- 5 token_dispatch -> MLP -> combine

SEW 最小插入点

- 在 fused_experts 前准备 slot weights;
- 不改 scheduler;
- 不改 model runner;
- 不重写 token dispatcher;
- 默认关闭, 通过配置开关启用。

低侵入原则: SEW-Offload 应作为 vllm_ascend/moe_offload/ 中的独立 runtime, 通过薄 hook 接入 MoE boundary; 现有 grouped count、dispatch、GMM 和 combine 尽量复用。

Policy design

MVP-0: observe

- 记录每层 active experts;
- 记录 expert_tokens;
- 分析 temporal locality;
- 不改变执行路径。

MVP-1: sync slot

- 固定 HBM slot 数;
- miss 同步加载;
- LRU/heat replacement;
- 保证 correctness。

MVP-2: prefetch

- 基于上一层/上一 token 预测;
- 对下一层 hot expert 预取;
- overlap routing/dispatch;
- 统计 stall 与命中。

MVP-3: graph-friendly window

将 slot 数、capacity tier 和权重入口固定成少量变体, 探索 ACLGraph/static kernel 对 offloaded expert path 的收益和限制。

Experiment plan

维度	设计
模型	Qwen3-30B-A3B; 优先单机单卡, 后续扩展多卡 expert parallel 对照
场景	人工限制 resident expert slots, 模拟 HBM 不足; 保留真实 KV cache 压力
Baseline 1	vLLM Ascend 原生 grouped MoE, 全量 expert 常驻
Baseline 2	简单 LRU expert cache, 无固定 slot/graph 设计
Baseline 3	GPU-style prediction/prefetch 思路移植, 不做 Ascend-specific slot 稳定化
SEW variants	sync slot、prefetch slot、capacity-tier slot、graph replay slot
Workloads	decode-heavy、mixed prefill/decode、长上下文、多请求连续批处理

Metrics and ablations

主要指标

- end-to-end throughput;
- TTFT / TPOT / p95 latency;
- HBM peak / resident expert memory;
- slot hit rate / miss penalty;
- H2D bytes and stalls;
- graph replay hit rate;
- MTE/Cube overlap。

消融实验

- slot 数量: 2/4/8/16;
- replacement: LRU、LFU、token-count weighted;
- prefetch: 无、上一层、上一 token、混合;
- capacity tier: 关闭/少量 bucket;
- graph: eager、ACLGraph、static kernel。

Expected claims

- ① **表示层 claim:** Ascend grouped MoE 已经提供 per-expert count; offloading 应复用这个信号, 而不是重新设计 routing。
- ② **系统层 claim:** 固定 expert-slot residency 能让 HBM 受限 MoE offloading 保持稳定权重入口, 减少动态权重对象破坏图复用的问题。
- ③ **硬件层 claim:** slot 化后, expert load/prefetch 可以与 routing、dispatch、GMM 形成更明确的流水, 有机会改善 MTE/Cube overlap。
- ④ **语义层 claim:** SEW-Offload 不修改 router、不减少 expert 激活、不做 drop, 因此 correctness 风险低于重路由或容量裁剪方法。

Risks and fallback

风险	表现	应对
slot miss 太多	加载阻塞吞吐，尾延迟升高	decode/prefill 分开评估；引入 token-count weighted replacement
graph 收益有限	dynamic count 仍导致图变体过多	先固定权重 slot 地址，再逐步引入 capacity tier
H2D 搬运太慢	offload 节省 HBM 但拖慢计算	量化 expert store、tile-level prefetch、异步加载
工程侵入过大	影响 vLLM Ascend 主路径稳定性	默认关闭；新包封装；先 observer，再 sync slot
正确性难验证	slot remap 引入 expert 对错风险	保留 expert-id checksum、逐层输出对齐、E2E replay 测试

Roadmap

Phase 1: Trace and evidence

实现 routed expert working-set 记录，得到 Qwen3-30B-A3B 在真实 workload 下的 expert locality、active set size、layer-to-layer overlap。

Phase 2: Minimal offloading

构建 host expert store 与固定 HBM slots，先用同步加载跑通 correctness，证明在人工 slot budget 下能替代全量 expert 常驻。

Phase 3: Ascend-specific optimization

加入 slot prefetch、capacity tier 和 graph/static-kernel 实验，验证固定 slot 地址是否能提升 replay 稳定性并降低搬运 stall。

一句话总结： SEW-Offload 的研究价值不在“让 MoE 后端按 expert 分组”，而在“当 expert 不能全量常驻 HBM 时，如何把动态 expert 工作集翻译成 Ascend 友好的固定 slot 执行窗口”。