

SEW-Offload: 面向昇腾 NPU 的 MoE Expert Offloading

Static Expert Slot Windowing for Ascend MoE Offloading

不要把 NPU 当 GPU 用： 研究重点不是重新发明 MoE grouped dispatch，而是在 HBM 受限时，利用 Ascend 的固定地址、图捕获、静态 kernel 和权重预取能力重新设计 expert offloading。

What is your problem

背景：MoE 总参数量快速增大，单卡 HBM 越来越不够

Qwen3-30B-A3B 这类 MoE 模型每个 token 只激活少量专家，但模型总专家权重仍然需要占用大量 HBM。当我们在单机单卡上服务更大 MoE，或者把更多 HBM 留给 KV cache、长上下文和并发请求时，expert 权重就自然进入 offloading 场景。

GPU offloading 的常见视角

- 哪些 expert 常驻 GPU；
- 哪些 expert 从 CPU/host 预取；
- 如何根据历史路由预测下轮 expert；
- 如何减少 PCIe/NVLink 搬运阻塞。

Ascend NPU 暴露的新问题

- NPU 后端更偏好固定 shape 与稳定执行图；
- expert 权重地址变化会破坏 graph/static-kernel 复用；
- MTE/权重预取、AIC/AIV 流水是显式控制面；
- grouped MoE 已有，但默认假设 expert 权重常驻。

核心问题： 在 Ascend 单卡 HBM 不足时，如何在**不修改 router、不改变 top-k 激活、不丢 token**的前提下，让 MoE expert offloading 既节省 HBM，又保持 NPU 喜欢的固定地址、固定形状和可预编译执行路径？

Old assumption fails: 旧 GPU 假设为什么不够

旧假设：expert cache 是主要问题

GPU MoE offloading 常把系统抽象成：

- router 产生动态 expert 集合；
- runtime 根据热度/预测决定加载哪些 expert；
- expert kernel 对当前 batch 动态执行；
- cache 命中率和传输带宽决定性能。

在 Ascend 上缺失的约束

如果只复制 GPU cache 策略，会忽略：

- graph capture 依赖稳定 tensor 形状和地址；
- static kernel 编译启动成本高，但重复执行收益大；
- MTE 搬运和 Cube 计算需要被流水化；
- 小而动态的 expert 执行会放大队列和调度开销。

重新定义 offloading： 在 Ascend 上，offloading 不只是“expert 在 host 和 device 之间移动”，还包括**权重驻留位置、slot 地址稳定性、图复用粒度、预取流水**这些 GPU 工作通常弱化的控制面。

Important correction: vLLM Ascend 已经做了什么

我们不能把已有 grouped MoE 后端当成新贡献。

路径	已有机制	含义
MC2	<code>npu_moe_distribute_dispatch</code> 返回 <code>expert_token_nums</code>	dispatch 后已有每个 expert 的累计 token 边界
AllGather	<code>npu_moe_init_routing</code> 返回 <code>expert_tokens</code>	token-level routing 被整理为 per-expert count
All2AllV	<code>torch.histc(topk_ids)</code> 统计 <code>tokens_per_expert</code>	expert 粒度统计用于通信和 GMM
MLP	<code>npu_grouped_matmul(... group_list=...)</code>	后端按 expert 分组执行矩阵乘

修正后的边界： vLLM Ascend 已经解决了“per-token assignment 到 per-expert count/grouped execution” 的表示问题。SEW-Offload 不能声称这是贡献；我们的目标是在此基础上解决HBM 不足时 expert 权重不再全量常驻的问题。

What is still missing: grouped count 不是 offloading window

已有 grouped MoE 后端

- 输入仍是每轮动态 topk_ids;
- group_list 的形状固定, 但 count 数值动态;
- GMM 根据每轮 split_value 决定 expert 的 M 维;
- 权重张量来自 layer.w13_weight/w2_weight。

Offloading 需要的新抽象

- HBM 中只有固定数量 expert_slots;
- expert_id -> slot_id 动态映射;
- slot 内权重 tensor 地址长期稳定;
- miss expert 触发加载、替换或慢速 fallback;
- slot 作为 graph/static-kernel 的稳定输入。

关键差异: grouped count 解决的是 activation 如何按 expert 执行; SEW-Offload 解决的是 expert 权重如何在 HBM 受限时以固定 slot 方式驻留、加载和复用。

Opportunity: Ascend 给 MoE offloading 的新控制面

Graph / static kernel

ACLGraph/NPUGraph 和 static kernel 更偏好固定 shape、固定 tensor 地址与有限执行变体。这意味着 expert offloading 应该尽量让 device 侧权重入口稳定。

Weight prefetch

vLLM Ascend 已经有通过额外 pipeline 预取线性层权重、降低 MTE 压力的经验。Expert slot 可以把“预取哪些权重”变成显式策略问题。


AIC/AIV/MTE 分工

MoE 执行天然包含 routing、permute、grouped GEMM、combine 与权重搬运。Ascend 的矩阵单元、向量单元和搬运单元让这些阶段有机会流水化。

Fixed GM window

如果 NPU 侧只有固定数量 slot，且每个 slot 的权重布局固定，runtime 可以把动态 expert 工作集翻译为稳定的 slot 执行窗口。

Key idea: Static Expert-Slot Windowing



核心理想： 不改变 router 选出的 expert；只是在执行前，把 active expert 映射到固定数量、固定地址的 HBM slots。命中的 expert 直接执行，未命中的 expert 触发加载/替换/降级路径。

Runtime abstraction

抽象	职责	为什么是 Ascend-specific
ExpertStore	CPU/host 侧保存完整 expert 权重, 支持按 expert 或 tile 加载	把 offloading 从一次性全量权重迁移变成可调度的数据搬运
SlotManager	维护固定数量 HBM slots 与 expert_id -> slot_id	固定 slot tensor 地址, 给 graph/static kernel 稳定入口
WindowPlanner	根据 group_list、历史热度和 HBM budget 选择 resident set	利用已有 per-expert count, 而不是重新做 routing
PrefetchEngine	在 routing/dispatch/GMM 间隙预取下一层或下一步 expert	显式利用 MTE/权重预取流水, 降低 Cube 等待
FallbackPath	处理 slot miss、超预算、预取失败和未覆盖 expert	保证不 drop token, 不改变模型语义

One iteration data flow

- ① **Routing:** 原始 router 产生 `topk_ids/topk_weights`, 不修改激活结果。
- ② **Count extraction:** 复用现有 `token_dispatcher.py` 得到 `group_list/expert_tokens`。
- ③ **Working-set planning:** 根据当前层 active experts、历史局部性和 slot budget 决定 resident set。
- ④ **Slot remap:** 将 active expert 映射到 `slot_id`, 构造 slot-local expert map。
- ⑤ **Load/prefetch:** 对 miss expert 从 host store 加载到空闲或被替换 slot。
- ⑥ **Grouped MLP:** 使用 slot 权重和现有 grouped matmul 路径执行。
- ⑦ **Combine:** 复用现有 `combine/unpermute`, 还原原始 token 顺序。

语义保证: SEW-Offload 只改变 expert 权重的驻留和访问方式, 不改变 router logits、top-k expert、gate weight 或 combine 语义。

Integration in vLLM Ascend

现有主路径

- 1 AscendFusedMoE.forward_impl
- 2 select_experts
- 3 build_fused_experts_input
- 4 moe_comm_method.fused_experts
- 5 token_dispatch -> MLP -> combine

SEW 最小插入点

- 在 fused_experts 前准备 slot weights;
- 不改 scheduler;
- 不改 model runner;
- 不重写 token dispatcher;
- 默认关闭, 通过配置开关启用。

低侵入原则: SEW-Offload 应作为 vllm_ascend/moe_offload/ 中的独立 runtime, 通过薄 hook 接入 MoE boundary; 现有 grouped count、dispatch、GMM 和 combine 尽量复用。

Policy design

MVP-0: observe

- 记录每层 active experts;
- 记录 expert_tokens;
- 分析 temporal locality;
- 不改变执行路径。

MVP-1: sync slot

- 固定 HBM slot 数;
- miss 同步加载;
- LRU/heat replacement;
- 保证 correctness。

MVP-2: prefetch

- 基于上一层/上一 token 预测;
- 对下一层 hot expert 预取;
- overlap routing/dispatch;
- 统计 stall 与命中。

MVP-3: graph-friendly window

将 slot 数、capacity tier 和权重入口固定成少量变体, 探索 ACLGraph/static kernel 对 offloaded expert path 的收益和限制。

Experiment plan

维度	设计
模型	Qwen3-30B-A3B; 优先单机单卡, 后续扩展多卡 expert parallel 对照
场景	人工限制 resident expert slots, 模拟 HBM 不足; 保留真实 KV cache 压力
Baseline 1	vLLM Ascend 原生 grouped MoE, 全量 expert 常驻
Baseline 2	简单 LRU expert cache, 无固定 slot/graph 设计
Baseline 3	GPU-style prediction/prefetch 思路移植, 不做 Ascend-specific slot 稳定化
SEW variants	sync slot、prefetch slot、capacity-tier slot、graph replay slot
Workloads	decode-heavy、mixed prefill/decode、长上下文、多请求连续批处理

Metrics and ablations

主要指标

- end-to-end throughput;
- TTFT / TPOT / p95 latency;
- HBM peak / resident expert memory;
- slot hit rate / miss penalty;
- H2D bytes and stalls;
- graph replay hit rate;
- MTE/Cube overlap。

消融实验

- slot 数量: 2/4/8/16;
- replacement: LRU、LFU、token-count weighted;
- prefetch: 无、上一层、上一 token、混合;
- capacity tier: 关闭/少量 bucket;
- graph: eager、ACLGraph、static kernel。

Expected claims

- ① **表示层 claim:** Ascend grouped MoE 已经提供 per-expert count; offloading 应复用这个信号, 而不是重新设计 routing。
- ② **系统层 claim:** 固定 expert-slot residency 能让 HBM 受限 MoE offloading 保持稳定权重入口, 减少动态权重对象破坏图复用的问题。
- ③ **硬件层 claim:** slot 化后, expert load/prefetch 可以与 routing、dispatch、GMM 形成更明确的流水, 有机会改善 MTE/Cube overlap。
- ④ **语义层 claim:** SEW-Offload 不修改 router、不减少 expert 激活、不做 drop, 因此 correctness 风险低于重路由或容量裁剪方法。

Risks and fallback

风险	表现	应对
slot miss 太多	加载阻塞吞吐，尾延迟升高	decode/prefill 分开评估；引入 token-count weighted replacement
graph 收益有限	dynamic count 仍导致图变体过多	先固定权重 slot 地址，再逐步引入 capacity tier
H2D 搬运太慢	offload 节省 HBM 但拖慢计算	量化 expert store、tile-level prefetch、异步加载
工程侵入过大	影响 vLLM Ascend 主路径稳定性	默认关闭；新包封装；先 observer，再 sync slot
正确性难验证	slot remap 引入 expert 对错风险	保留 expert-id checksum、逐层输出对齐、E2E replay 测试

Roadmap

Phase 1: Trace and evidence

实现 routed expert working-set 记录，得到 Qwen3-30B-A3B 在真实 workload 下的 expert locality、active set size、layer-to-layer overlap。

Phase 2: Minimal offloading

构建 host expert store 与固定 HBM slots，先用同步加载跑通 correctness，证明在人工 slot budget 下能替代全量 expert 常驻。

Phase 3: Ascend-specific optimization

加入 slot prefetch、capacity tier 和 graph/static-kernel 实验，验证固定 slot 地址是否能提升 replay 稳定性并降低搬运 stall。

一句话总结： SEW-Offload 的研究价值不在“让 MoE 后端按 expert 分组”，而在“当 expert 不能全量常驻 HBM 时，如何把动态 expert 工作集翻译成 Ascend 友好的固定 slot 执行窗口”。