

ASC-CORE Batch 1 同步处理日志

分支: qingwanruojun/sync-asc-core-b1

日期: 2026-06-25

操作人: qingwanruojun

处理记录

#	PR	标题	决定	原因
1	#9049	[BugFix] Use non-device-specific triton pow function	☒ 接受	上游官方改进，移除了过时的 Ascend 专属写法
2	#9312	[Bugfix] ascend_config: use truthy check for enforce_eager	☒ 接受	Python 最佳实践改进，无冲突
3	#9240	[BugFix] Update cudagraph mode handling for encoder-decoder	☒ 接受	昇腾平台 encoder-decoder 优化，无冲突
4	#9193	[BugFix] Fix UB overflow caused by NPUir upgrade	☒ 接受	修 NPUir 升级后的未定义行为溢出，1行改动
5	#9456	[BugFix] Fix Deepseek-V4 async scheduling with MTP	☒ 接受	修 Deepseek-V4 的 MTP 异步调度 bug，3处冲突已解决
6	#9500	[BugFix] Fix Deepseek-V4 P/D disaggregation kv_cache_tensor	☒ 接受	修分离式推理 kv_cache 为空的问题，1处冲突已解决
7	#9510	[BugFix] Use Compress ratio to avoid obtaining illegal attrib	☒ 接受	加压缩比例判断避免读到非法属性，无冲突

处理详情

PR #9049 — [BugFix] Use non-device-specific triton pow function

链接: <https://github.com/vllm-project/vllm-ascend/pull/9049>

类型: BugFix

文件: `vllm_ascend/worker/v2/sample/penalties.py` (第 25 行)

改动详情:

```
- pow = triton.language.extra.ascend.libdevice.pow
+ pow = triton.language.extra.libdevice.pow
```

说明: 新版 triton 已内置支持, 不再需要 `.ascend` 前缀。把写死的昇腾专属调用改成通用调用。

冲突: 有 — fork 版本还是旧的 `.ascend` 写法

处理: 接受上游版本

PR #9312 — [Bugfix] ascend_config: use truthy check for enforce_eager

链接: <https://github.com/vllm-project/vllm-ascend/pull/9312>

类型: BugFix

文件: `vllm_ascend/ascend_config.py` (第 357 行)

改动详情:

```
- if vllm_config.model_config.enforce_eager is True:
+ if vllm_config.model_config.enforce_eager:
```

说明: Python 最佳实践: `enforce_eager` 可能是 `True` 或其他 truthy 值, 用 `is True` 可能漏判。改成 truthy 检查更健壮。

冲突: 无

处理: 自动合并成功

PR #9456 — [BugFix] Fix Deepseek-V4 async scheduling with MTP

链接: <https://github.com/vllm-project/vllm-ascend/pull/9456>

类型: BugFix

文件: `vllm_ascend/worker/model_runner_v1.py`

改动详情:

- 新增 `_dsa_positions_cpu_buf` 和 `_dsa_positions_np_buf` 缓冲区 (用于 Deepseek-V4 专属)
- 优化 stream 同步: `torch.npu.current_stream()` 提前引用, 避免重复调用
- 新增 `self.use_compress` 分支下的 DSA 位置计算逻辑
- 在 `_build_attention_metadata` 调用中传入 `positions_cpu` 参数
- 在 dummy build 和 force_attention 场景下同步重置 `_dsa_positions_cpu_buf`

冲突: 3处 — 均为 fork 缺少上游新增的代码段

处理: 接受上游版本

PR #9500 — [BugFix] Fix Deepseek-V4 P/D disaggregation kv_cache_tensor.shared_by may be empty

链接: <https://github.com/vllm-project/vllm-ascend/pull/9500>

类型: BugFix

文件: `vllm_ascend/distributed/kv_transfer/kv_p2p/mooncake_hybrid_connector.py`

改动详情:

```
        for kv_cache_tensor in self.kv_cache_config.kv_cache_tensors:
+           if not kv_cache_tensor.shared_by:
+               continue
            share_tensor_addr = []
```

说明: Deepseek-V4 分离式推理时 `kv_cache_tensor.shared_by` 可能为空, 不加判断直接访问会崩溃。加了个 `continue` 跳过空值。

冲突: 1处 — fork 未包含此文件路径 (上游新增文件)

处理: 接受上游版本 (文件为上游新增)

PR #9510 — [BugFix] Use Compress ratio to avoid obtaining illegal attributes

链接: <https://github.com/vllm-project/vllm-ascend/pull/9510>

类型: BugFix

文件: `vllm_ascend/distributed/kv_transfer/kv_p2p/mooncake_hybrid_connector.py`

改动详情:

```
-         if cur_tensor_group_idx:
+         if cur_tensor_group_idx and compress_ratio > 0:
```

说明: 在访问属性前先检查 `compress_ratio` 是否合法 (>0) , 避免读取非法属性导致崩溃。

冲突: 无

处理: 自动合并成功

PR #9240 — [BugFix] Update cudagraph mode handling for encoder-decoder models

链接: <https://github.com/vllm-project/vllm-ascend/pull/9240>

类型: BugFix

文件: `vllm_ascend/platform.py` (第 383-400 行)

改动详情:

```
-         if model_config and model_config.is_encoder_decoder is True:
-             if compilation_config.cudagraph_mode ==
CUDAGraphMode.FULL_DECODE_ONLY:
-                 logger.warning(...)
-                 compilation_config.cudagraph_mode = CUDAGraphMode.PIECEWISE
+         if (
+             model_config
+             and model_config.is_encoder_decoder
+             and compilation_config.cudagraph_mode not in (CUDAGraphMode.NONE,
CUDAGraphMode.PIECEWISE)
+         ):
+             cudagraph_mode = (
+                 CUDAGraphMode.PIECEWISE
+                 if compilation_config.mode == CompilationMode.VLLM_COMPILE
+                 else CUDAGraphMode.NONE
+             )
+             logger.info_once(...)
+             compilation_config.cudagraph_mode = cudagraph_mode
```

说明: 优化 encoder-decoder 模型的 cudagraph 模式处理逻辑: 1) 增加 `NONE` 模式的兜底 2) 区分 `VLLM_COMPILE` 模式用 `PIECEWISE`, 其他情况用 `NONE` 3) 用 `info_once` 替代 `warning` 减少日志刷屏

冲突: 无

处理: 自动合并成功

PR #9456 — [BugFix] Fix Deepseek-V4 async scheduling with MTP

链接: <https://github.com/vllm-project/vllm-ascend/pull/9456>

类型: BugFix

文件: `vllm_ascend/worker/model_runner_v1.py`

改动详情:

- 新增 `_dsa_positions_cpu_buf` 和 `_dsa_positions_np_buf` 缓冲区 (用于 Deepseek-V4 专属)
- 优化 stream 同步: `torch.npu.current_stream()` 提前引用, 避免重复调用
- 新增 `self.use_compress` 分支下的 DSA 位置计算逻辑
- 在 `_build_attention_metadata` 调用中传入 `positions_cpu` 参数
- 在 dummy build 和 force_attention 场景下同步重置 `_dsa_positions_cpu_buf`

冲突: 3处 — 均为 fork 缺少上游新增的代码段

处理: 接受上游版本

PR #9500 — [BugFix] Fix Deepseek-V4 P/D disaggregation kv_cache_tensor.shared_by may be empty

链接: <https://github.com/vllm-project/vllm-ascend/pull/9500>

类型: BugFix

文件: `vllm_ascend/distributed/kv_transfer/kv_p2p/mooncake_hybrid_connector.py`

改动详情:

```
for kv_cache_tensor in self.kv_cache_config.kv_cache_tensors:
+     if not kv_cache_tensor.shared_by:
+         continue
    share_tensor_addr = []
```

说明: Deepseek-V4 分离式推理时 `kv_cache_tensor.shared_by` 可能为空, 不加判断直接访问会崩溃。加了个 `continue` 跳过空值。

冲突: 1处 — fork 未包含此文件路径 (上游新增文件)

处理: 接受上游版本 (文件为上游新增)

PR #9510 — [BugFix] Use Compress ratio to avoid obtaining illegal attributes

链接: <https://github.com/vllm-project/vllm-ascend/pull/9510>

类型: BugFix

文件: `vllm_ascend/distributed/kv_transfer/kv_p2p/mooncake_hybrid_connector.py`

改动详情:

```
-         if cur_tensor_group_idx:
+         if cur_tensor_group_idx and compress_ratio > 0:
```

说明: 在访问属性前先检查 `compress_ratio` 是否合法 (>0) , 避免读取非法属性导致崩溃。

冲突: 无

处理: 自动合并成功

PR #9193 — [BugFix] Fix UB overflow caused by compatibility issues after NPUIR upgrade

链接: <https://github.com/vllm-project/vllm-ascend/pull/9193>

类型: BugFix

文件: `vllm_ascend/worker/v2/sample/logprob.py` (第 46 行)

改动详情:

```
-         max_val = t1.max(t1.maximum(logits, max_val))
+         max_val = t1.max(t1.maximum(logits, max_val,
+ propagate_nan=t1.PropagateNan.ALL))
```

说明: NPUIR 升级后 `t1.maximum` 的行为变了, 不加 `propagate_nan` 会导致未定义行为 (UB) 溢出。加了参数显式指定 NaN 传播方式。

冲突: 无

处理: 自动合并成功

PR #9456 — [BugFix] Fix Deepseek-V4 async scheduling with MTP

链接: <https://github.com/vllm-project/vllm-ascend/pull/9456>

类型: BugFix

文件: `vllm_ascend/worker/model_runner_v1.py`

改动详情:

- 新增 `_dsa_positions_cpu_buf` 和 `_dsa_positions_np_buf` 缓冲区 (用于 Deepseek-V4 专属)
- 优化 stream 同步: `torch.npu.current_stream()` 提前引用, 避免重复调用
- 新增 `self.use_compress` 分支下的 DSA 位置计算逻辑
- 在 `_build_attention_metadata` 调用中传入 `positions_cpu` 参数
- 在 dummy build 和 force_attention 场景下同步重置 `_dsa_positions_cpu_buf`

冲突: 3处 — 均为 fork 缺少上游新增的代码段

处理: 接受上游版本

PR #9500 — [BugFix] Fix Deepseek-V4 P/D disaggregation kv_cache_tensor.shared_by may be empty

链接: <https://github.com/vllm-project/vllm-ascend/pull/9500>

类型: BugFix

文件: `vllm_ascend/distributed/kv_transfer/kv_p2p/mooncake_hybrid_connector.py`

改动详情:

```
        for kv_cache_tensor in self.kv_cache_config.kv_cache_tensors:
+           if not kv_cache_tensor.shared_by:
+               continue
            share_tensor_addr = []
```

说明: Deepseek-V4 分离式推理时 `kv_cache_tensor.shared_by` 可能为空，不加判断直接访问会崩溃。加了个 `continue` 跳过空值。

冲突: 1处 — fork 未包含此文件路径（上游新增文件）

处理: 接受上游版本（文件为上游新增）

PR #9510 — [BugFix] Use Compress ratio to avoid obtaining illegal attributes

链接: <https://github.com/vllm-project/vllm-ascend/pull/9510>

类型: BugFix

文件: `vllm_ascend/distributed/kv_transfer/kv_p2p/mooncake_hybrid_connector.py`

改动详情:

```
-         if cur_tensor_group_idx:
+         if cur_tensor_group_idx and compress_ratio > 0:
```

说明: 在访问属性前先检查 `compress_ratio` 是否合法 (>0)，避免读取非法属性导致崩溃。

冲突: 无

处理: 自动合并成功